به نام خدا



دانشگاه صنعتی شریف

فرایندهای تصادفی
پاییز و زمستان ۱۴۰۵
حمیدرضا ربیعی

کوئیز ۰ | Probability and Statistics | تاریخ: ۵ آبان

1. دو پژوهشگر یک مجموعه‌داده‌ی یکسان را با استفاده از یک مدل Bayesian تحلیل می‌کنند. فرض کنید:

$$X_1, \dots, X_n \mid \theta \overset{iid}{\sim} N(\theta, 4), \qquad \sigma^2 = 4$$

دو پژوهشگر به دلایل علمی متفاوت، توزیع‌های پیشین (prior) زیر را برای پارامتر θ در نظر می‌گیرند:

$$\text{پژوهشگر A:} \quad \theta \sim N(0, 4)$$
$$\text{پژوهشگر B:} \quad \theta \sim N(4, 4)$$

فرض کنید تعداد مشاهدات $n = 4$ و میانگین داده‌های مشاهده‌شده برابر $\bar{X} = 2$ باشد.
می‌دانیم اگر توزیع پیشین به‌صورت $\theta \sim N(\mu_0, \tau_0^2)$ باشد، میانگین توزیع پسین (posterior) از رابطه‌ی زیر به دست می‌آید:

$$E(\theta \mid X) = \frac{\frac{n}{\sigma^2}\bar{X} + \frac{1}{\tau_0^2}\mu_0}{\frac{n}{\sigma^2} + \frac{1}{\tau_0^2}}$$

که در آن μ_0 و τ_0^2 به‌ترتیب میانگین و واریانس توزیع پیشین و σ^2 واریانس توزیع مشاهدات در مدل درست‌نمایی (likelihood) هستند.
به پرسش‌های زیر پاسخ دهید:

(a) میانگین پسین را برای هر دو پژوهشگر محاسبه کنید. آیا متفاوت بودن نتایج به معنای نادرست بودن یکی از تحلیل‌هاست؟ پاسخ خود را توضیح دهید. (۱۰ نمره)

(b) فرض کنید تعداد مشاهدات به $n = 20$ افزایش یابد و میانگین نمونه همچنان برابر 2 باقی بماند.
میانگین پسین هر دو پژوهشگر را دوباره محاسبه کنید. اختلاف میانگین‌های پسین را در دو حالت $n = 4$ و $n = 20$ مقایسه کرده و نتیجه را تفسیر کنید. (۱۰ نمره)

(c) با استفاده از فرمول داده‌شده، بررسی کنید که اگر n به سمت بی‌نهایت میل کند و میانگین نمونه برابر 2 باقی بماند، میانگین پسین هر پژوهشگر به چه مقداری نزدیک می‌شود.
آیا می‌توان نتیجه گرفت که با افزایش حجم داده‌ها، دو پژوهشگر بیزی الزاماً در همه‌ی مسائل به نتایج یکسان خواهند رسید؟ توضیح دهید. (۱۰ نمره)

(d) این مثال را از منظر عینیت (objectivity) در استنباط آماری تحلیل کنید و آن را با رویکرد Frequentist مقایسه کنید. آیا وابستگی تحلیل Bayesian به prior لزوماً به این معناست که رویکرد Frequentist عینی‌تر است؟ منظور از عینیت در اینجا این است که تا چه حد نتیجه‌ی استنباط باید مستقل از قضاوت‌ها، ترجیحات یا انتخاب‌های شخصی پژوهشگر باشد و تا چه حد انتظار داریم دو پژوهشگر با داده‌ی یکسان به نتیجه‌ی مشابه برسند. (۱۰ نمره)

2. فرض کنید

$$X \sim \text{Uniform}(-1, 1), \qquad Y = X^2.$$

رابطه‌ی بین X و Y را از نظر correlation و independence تحلیل کنید. آیا correlation در این مثال وابستگی بین دو متغیر را به‌طور کامل نشان می‌دهد؟ توضیح دهید. (۲۵ نمره)

3. برای هر مسئله، مناسب‌ترین توزیع را از میان گزینه‌های زیر انتخاب کنید. (نیازی به ارائه‌ی توضیح نیست و فقط نام توزیع را بنویسید.)

Gaussian – Binomial – Poisson – Exponential – Uniform

A. در یک سیستم مخابراتی، در هر بازه‌ی زمانی بسیار کوتاه احتمال ورود بیش از یک packet ناچیز است، رخدادهای بازه‌های جدا از هم مستقل فرض می‌شوند و نرخ متوسط ورود در زمان ثابت است. متغیر موردنظر، **تعداد packetهای دریافت‌شده در یک بازه‌ی زمانی مشخص** است. (۷ نمره)

B. همان سیستم بالا را در نظر بگیرید. این بار متغیر موردنظر، **مدت زمانی از یک ورود تا ورود بعدی** است. (۷ نمره)

C. یک الگوریتم تشخیص روی n ورودی مستقل اجرا می‌شود. هر ورودی با احتمال ثابت p به‌درستی تشخیص داده می‌شود و متغیر موردنظر، **تعداد تشخیص‌های صحیح از میان n اجرا** است. (۷ نمره)

D. خطای نهایی یک حسگر حاصل جمع تعداد زیادی مؤلفه‌ی خطای کوچک است که منشأهای متفاوت دارند و هیچ‌کدام به‌تنهایی سهم غالبی در خطای نهایی ندارند. متغیر موردنظر، **خطای کل اندازه‌گیری** است. (۷ نمره)

E. فاز اولیه‌ی یک سیگنال سینوسی پیش از مشاهده ناشناخته است و هیچ جهت یا فاز خاصی نسبت به دیگری ترجیح داده نمی‌شود. متغیر موردنظر، **فاز اولیه در یک چرخه‌ی کامل** است. (۷ نمره)

1. (a) برای محاسبه‌ی میانگین پسین از رابطه‌ی زیر استفاده می‌کنیم:

$$E(\theta \mid X) = \frac{\frac{n}{\sigma^2}\bar{X} + \frac{1}{\tau_0^2}\mu_0}{\frac{n}{\sigma^2} + \frac{1}{\tau_0^2}}$$

با توجه به $n = 4$، $\bar{X} = 2$، $\sigma^2 = 4$ و $\tau_0^2 = 4$، برای پژوهشگر A داریم:

$$E_A(\theta \mid X) = \frac{\frac{4}{4}(2) + \frac{1}{4}(0)}{\frac{4}{4} + \frac{1}{4}} = \frac{2}{1.25} = 1.6$$

برای پژوهشگر B نیز داریم:

$$E_B(\theta \mid X) = \frac{\frac{4}{4}(2) + \frac{1}{4}(4)}{\frac{4}{4} + \frac{1}{4}} = \frac{3}{1.25} = 2.4$$

بنابراین اختلاف میانگین‌های پسین برابر است با:

$$|2.4 - 1.6| = 0.8$$

متفاوت بودن نتایج الزاماً نشان نمی‌دهد که یکی از تحلیل‌ها نادرست است، زیرا در استنباط بیزی، پسین حاصل ترکیب پیشین و درست‌نمایی است. پیشین‌های متفاوت اما قابل‌دفاع می‌توانند به نتایج متفاوت منجر شوند.

(b) با افزایش تعداد مشاهدات به $n = 20$ و ثابت ماندن $\bar{X} = 2$، برای پژوهشگر A داریم:

$$E_A(\theta \mid X) = \frac{\frac{20}{4}(2) + \frac{1}{4}(0)}{\frac{20}{4} + \frac{1}{4}} = \frac{10}{5.25} \approx 1.905$$

برای پژوهشگر B:

$$E_B(\theta \mid X) = \frac{\frac{20}{4}(2) + \frac{1}{4}(4)}{\frac{20}{4} + \frac{1}{4}} = \frac{11}{5.25} \approx 2.095$$

اختلاف میانگین‌های پسین در دو حالت برابر است با:

$$\begin{aligned} n = 4: &\quad |2.4 - 1.6| = 0.8 \\ n = 20: &\quad |2.095 - 1.905| \approx 0.190 \end{aligned}$$

بنابراین با افزایش حجم نمونه، اختلاف میانگین‌های پسین کاهش یافته است. این نتیجه نشان می‌دهد که با افزایش داده‌ها، تأثیر نسبی پیشین کاهش می‌یابد و اطلاعات حاصل از داده‌ها نقش بیشتری پیدا می‌کنند.

(c) با جایگذاری مقادیر مسئله در فرمول میانگین پسین داریم:

$$E(\theta \mid X) = \frac{\frac{n}{4}(2) + \frac{1}{4}\mu_0}{\frac{n}{4} + \frac{1}{4}} = \frac{2n + \mu_0}{n + 1}$$

برای پژوهشگر A:

$$E_A(\theta \mid X) = \frac{2n}{n + 1}$$

بنابراین:

$$\lim_{n \to \infty} E_A(\theta \mid X) = 2$$

برای پژوهشگر B:

$$E_B(\theta \mid X) = \frac{2n + 4}{n + 1}$$

در نتیجه:

$$\lim_{n\to\infty} E_B(\theta \mid X) = 2$$

همچنین اختلاف میانگین‌های پسین برابر است با:

$$\Delta_n = \left|\frac{2n+4}{n+1} - \frac{2n}{n+1}\right| = \frac{4}{n+1}$$

و در نتیجه:

$$\lim_{n\to\infty} \Delta_n = 0$$

بنابراین در این مدل، با افزایش حجم نمونه، میانگین‌های پسین دو پژوهشگر به یکدیگر نزدیک می‌شوند.
با این حال، این همگرایی در همه‌ی مسائل بیزی تضمین‌شده نیست. برای مثال، اگر پیشین به ناحیه‌ی حاوی مقدار واقعی پارامتر احتمال صفر اختصاص دهد یا مدل قابل‌شناسایی نباشد، ممکن است اثر پیشین حتی با داده‌های بسیار زیاد باقی بماند.

(d) از منظر عینیت (objectivity)، وابستگی Bayesian inference به prior می‌تواند نتیجه را تا حدی به انتخاب پژوهشگر وابسته کند. با این حال، Frequentist inference نیز کاملاً عاری از انتخاب‌های پژوهشگر نیست؛ انتخاب مدل، آزمون آماری، سطح معنی‌داری، sampling design و stopping rule می‌توانند روی نتیجه اثر بگذارند. بنابراین تفاوت اصلی بیشتر در محل ورود assumptions و انتخاب‌های پژوهشگر است، نه در اینکه یکی کاملاً عینی و دیگری کاملاً ذهنی باشد.

2. چون توزیع X نسبت به صفر متقارن است،

$$E[X] = 0, \qquad E[X^3] = 0.$$

از آنجا که

$$Y = X^2,$$

داریم

$$\mathrm{Cov}(X, Y) = E[X^3] - E[X]E[X^2] = 0.$$

پس correlation بین X و Y نیز صفر است.
با این حال، X و Y مستقل نیستند، زیرا Y مستقیماً از X تعیین می‌شود. با دانستن $Y = y$ می‌دانیم

$$|X| = \sqrt{y}.$$

بنابراین مشاهده‌ی Y اطلاعاتی درباره‌ی X فراهم می‌کند. این مثال نشان می‌دهد که correlation فقط وابستگی خطی را اندازه می‌گیرد و صفر بودن آن لزوماً به معنای independence نیست.

3. A. Poisson
چون تعداد رخدادها در یک بازه‌ی زمانی، با نرخ ثابت و رخدادهای مستقل، مدل می‌شود.

B. Exponential
چون زمان بین رخدادهای یک فرایند Poisson با توزیع Exponential مدل می‌شود.

C. Binomial
چون تعداد موفقیت‌ها در n آزمایش مستقل با احتمال موفقیت ثابت p شمرده می‌شود.

D. Gaussian
چون متغیر موردنظر حاصل جمع تعداد زیادی مؤلفه‌ی کوچک و تقریباً مستقل است و تحت شرایط مناسب می‌توان از تقریب Gaussian استفاده کرد.

E. Uniform
چون هیچ مقدار فازی در یک چرخه نسبت به مقدار دیگر ترجیح داده نشده است.